



南开大学
Nankai University

南 开 大 学

计 算 机 学 院

《深度学习与应用》期末大作业

基于深度学习的显著性目标检测方法研究

成员 1: 陈天祺 2313857 计算机科学与技术

成员 2: 邵莫涵 2311366 计算机科学与技术

成员 3: 杨欣瑞 2312246 计算机科学与技术

2026 年 6 月 3 日

目录

一、摘要	1
二、引言	1
三、相关工作	1
1、基于 CNN 的显著性检测方法	1
四、Baseline 方法	1
1、ResNet	1
1.1 基本原理	1
1.2 网络结构	1
1.3 基于 ResNet 的显著目标检测网络	2
2、PoolNet	2
2.1 基本思想	2
2.2 金字塔池化模块 (PPM)	3
2.3 深度池化特征融合 (Deep Pooling Layer)	3
3、F ³ Net	3
4、CPD Net	3
五、探索与创新	3
1、网络整体结构	3
2、损失函数设计	3
六、实验	3
1、数据集	3
2、评价指标	4
2.1 F-measure	4
2.2 Weighted F-measure	4
2.3 MAE	4
2.4 E-measure	5
3、实验设置	5
4、实验结果对比	6
5、消融实验	6
6、可视化结果分析	6
七、成员分工	7
八、总结与展望	7

一、 摘要

本报告围绕显著性目标检测任务展开，以 ResNet-18 [1] 为骨干网络，系统研究了基于深度学习的显著图预测方法。

关键词：显著性目标检测；ResNet-18；编解码器；注意力机制；多尺度融合

二、 引言

显著性目标检测（Salient Object Detection, SOD）旨在从自然图像中定位并分割出最吸引人类视觉注意力的前景区域，输出与输入图像等尺寸的二值或软性预测掩码（mask）。该任务在图像检索、视频理解、自动驾驶等领域具有广泛的应用价值。

传统方法主要依赖于在手工设计的特征下进行，难以适应复杂图像场景和结构，泛化能力有限。随着深度学习的发展，基于卷积神经网络的方法在语义特征提取上取得了显著进步，成为当前的主流范式。我们的贡献总结如下：

1. 实现了两种基于 ResNet-18 的基线方法（FCN 解码器与 U-Net 跳跃连接解码器）并进行对比分析；
2. 提出了融合边缘增强分支、通道注意力与多尺度特征融合的改进网络（ResSOD-Improved）；
3. 设计了结合二值交叉熵（BCE）与结构相似性（SSIM）的混合损失函数；
4. 在 DUTS 数据集上进行了系统的消融实验，定量验证了各模块的贡献。

三、 相关工作

1、 基于 CNN 的显著性检测方法

四、 Baseline 方法

1、 ResNet

1.1 基本原理

残差网络（Residual Network, ResNet）是深度卷积神经网络中的经典骨干结构 [1]，其核心思想是通过残差连接缓解深层网络训练中的退化问题。与传统卷积网络直接学习目标映射 $H(x)$ 不同，残差网络学习的是输入与输出之间的残差部分 $F(x) = H(x) - x$ 。这种设计使得网络在加深时更容易学习恒等映射，从而降低深层网络的优化难度。

残差块（Residual Block）是 ResNet 的基本组成单元（图 4.1），主要由残差分支和捷径分支两部分构成。残差分支用于对输入特征进行非线性变换，捷径分支则将输入特征直接传递到输出端，并与残差分支的输出进行逐元素相加。

1.2 网络结构

ResNet 通常由一个初始卷积层和若干个残差阶段组成（图 4.2）。以 ImageNet 版 ResNet 为例，输入图像先经过 7×7 conv + BN + ReLU + maxpool 得到低层特征，然后依次经历 layer1、layer2、layer3、layer4 四个残差阶段。

每个阶段由多个残差块组成，空间分辨率逐步下降，通道数逐步增加。一般情况下，ResNet18/34 使用 BasicBlock，ResNet50/101 使用更深的 Bottleneck Block。




图 4.1: Residual block

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

图 4.2: ResNet 网络结构

1.3 基于 ResNet 的显著目标检测网络

显著目标检测 (Salient Object Detection, SOD) 旨在从图像中预测最具视觉吸引力的前景区域。由于该任务需要生成像素级显著图，因此网络既需要高层语义信息来定位显著目标，又需要低层空间信息来恢复目标边界。

基于 ResNet 的显著目标检测网络通常采用编码器-解码器 (Encoder-Decoder) 结构。其中 ResNet 作为编码器提取多尺度特征，解码器负责融合不同层级特征并生成显著图。

$$S = D(C_1, C_2, C_3, C_4)$$

其中 C_1, C_2, C_3, C_4 表示解码器输出的各层级特征， $D(\cdot)$ 表示解码器， S 表示输出显著图。

2、 PoolNet

2.1 基本思想

PoolNet 是一种基于编码器—解码器结构的显著目标检测网络，其核心思想是充分融合深层语义信息与浅层空间细节信息，从而生成区域完整、边界清晰的显著性预测图。PoolNet 的核心创新点在于：

- **全局上下文增强**：通过顶层特征的多尺度池化，使网络感受野扩大，可区分局部高对比度背景与真正显著目标。
- **多尺度特征融合**：通过自顶向下的解码过程将高层语义信息与浅层空间信息融合，增强浅层特征的表达能力并抑制噪声。

2.2 金字塔池化模块 (PPM)

PoolNet 引入**金字塔池化模块 (Pyramid Pooling Module, PPM)** 用于捕获多尺度上下文信息。对于深层输入特征 $X_{\text{deep}} \in \mathbb{R}^{B \times C \times H/32 \times W/32}$ ，首先经过多尺度自适应平均池化形成多尺度全局上下文特征：

$$X_s = \text{Upsample}\left(\text{AvgPool}_s(X_{\text{deep}})\right)$$

其中 $s \in \{1, 3, 5\}$ 表示不同池化输出尺寸，Upsample 将池化特征上采样回深层特征分辨率。然后再与原始深层特征进行拼接增强：

$$X_{\text{PPM}} = \text{Conv}\left([X_{\text{deep}}, X_1, X_3, X_5]\right)$$

PPM 输出随后上采样到浅层特征尺寸，用作 **Global Guiding Flow (GGF)**，为解码器提供全局语义指导。

2.3 深度池化特征融合 (Deep Pooling Layer)

在解码阶段，PoolNet 采用自顶向下融合的策略，核心模块是深度池化层 (Deep Pooling Layer, DPL)。其处理流程为：

1. 高层特征 F_{high} 上采样至当前层特征分辨率，并与当前层特征 F_{skip} 及 GGF 全局信号特征 F_{info} 相加。

$$F_{\text{merge}} = F_{\text{high}}^{\uparrow} + F_{\text{skip}} + F_{\text{info}}$$

2. 对融合后的特征执行多尺度平均池化 (Adaptive Average Pooling)，最后每个池化分支通过卷积和 ReLU 后上采样回原始分辨率，融合不同尺度的上下文信息，从而增强感受野。

$$F_{\text{pool}} = F_{\text{merge}} + \sum_{s \in \{2, 4, 8\}} \text{Upsample}\left(\text{AvgPool}_s(F_{\text{merge}})\right)$$

3. 对融合后的特征进行卷积整合。

$$F_{\text{out}} = F_{3 \times 3}(F_{\text{pool}})$$

这种自顶向下的融合策略保证了浅层特征同时拥有高分辨率空间信息和深层语义信息，提升显著图对边缘和细节的敏感性，同时抑制浅层噪声干扰。

3、 F³ Net

4、 CPD Net

五、 探索与创新

1、 网络整体结构

2、 损失函数设计

六、 实验

1、 数据集

本实验采用 ECSSD 数据集 [2] 进行模型训练与测试。ECSSD 是显著性目标检测领域常用的基准数据集之一，共包含 1,000 张自然场景图像及其对应的像素级显著性标注图。数据集中的每张图像均配有手工标注的 Ground Truth，用于标识图像中的显著目标区域，可用于模型训练、验证以及定量评估。

ECSSD 数据集主要由复杂自然场景图像组成，图像内容涵盖动物、人物、植物、人工物体以及多种日常场景。相比于早期较简单的显著性检测数据集，ECSSD 在场景复杂度、目标外观变化和背景干扰程




图 6.1: ECSSD Dataset Samples

度上更具挑战性。数据集中常见目标边界不规则、前景与背景对比不明显、目标尺度差异较大、背景纹理复杂以及多个显著区域共存等情况，因此能够较好地反映自然场景下显著目标检测任务的实际难度。

2、 评价指标

2.1 F-measure

F-measure 是 Precision 和 Recall 的加权调和平均，用于综合衡量模型的准确性和完整性。其定义为：

$$F_{\beta} = \frac{(1 + \beta^2) \cdot Precision \cdot Recall}{\beta^2 \cdot Precision + Recall}$$

其中， β 用于调节 Precision 和 Recall 的相对重要性，通常设置 $\beta^2 = 0.3$ 。F-measure 数值越大，说明模型在显著目标区域检测的准确性和完整性方面表现越好。

2.2 Weighted F-measure

Weighted F-measure (F_{β}^w) 是传统 F-score 的加权扩展形式，用于更加准确地评价显著性检测结果。普通 F-score 主要依据像素级 Precision 和 Recall 计算模型性能，但对预测误差的空间位置和结构影响考虑不足。为此， F_{β}^w 引入加权机制，对不同区域的预测误差赋予不同权重，从而能够更好地反映显著目标的区域完整性、边界质量以及背景抑制效果。其定义为：

$$F_{\beta}^w = \frac{(1 + \beta^2) \cdot Precision^w \cdot Recall^w}{\beta^2 \cdot Precision^w + Recall^w}$$

其中， $Precision^w$ 表示加权准确率， $Recall^w$ 表示加权召回率， β 用于调节二者的相对重要性。 F_{β}^w 数值越大，说明预测显著图与真实标注图在像素分布和空间结构上越一致，模型的显著性检测性能越好。

2.3 MAE

MAE (Mean Absolute Error) 表示平均绝对误差，用于衡量预测显著图与真实标注图之间的像素级差异。其定义为：

$$MAE = \frac{1}{W \times H} \sum_{x=1}^W \sum_{y=1}^H |S(x, y) - G(x, y)|$$

其中, S 表示预测显著图, G 表示真实标注图。MAE 直接在连续显著图上进行计算, 不依赖于二值化阈值。因此, MAE 能够反映预测图与真实标注图在整体像素层面的接近程度。MAE 数值越小, 说明模型生成的显著图与真实标注越接近, 预测误差越低。

2.4 E-measure

E-measure (Enhanced-alignment Measure) 是一种综合考虑全局统计信息与局部像素匹配关系的显著性检测评价指标, 用于衡量预测显著图与真实标注图之间的整体对齐程度和结构一致性。其定义为:

$$E_{\phi} = \frac{1}{W \times H} \sum_{x=1}^W \sum_{y=1}^H \phi(x, y)$$

其中, $\phi(x, y)$ 表示增强对齐矩阵在像素位置 (x, y) 处的取值, W 和 H 分别表示图像的宽度和高度。E-measure 在评价过程中不仅关注预测结果与真实标注之间的像素级差异, 还引入了全局均值信息来刻画二者在整体区域分布上的一致性。因此, 相比仅基于像素分类结果的评价指标, E-measure 能够更全面地反映显著目标区域的完整性、前景与背景的区分能力以及预测结果的结构质量。E-measure 越大表示预测显著图与真实标注图之间的一致性越高, 模型的显著性检测效果越好。

3、 实验设置

实现细节 本项目实验基于 PyTorch 深度学习框架实现, 训练和评估分别由 `src/main.py` 与 `src/eval.py` 完成, 各模型均采用 ImageNet 预训练的 ResNet-18 作为骨干网络, 其余新建层随机初始化。训练时通过 `--model` 指定模型, 默认模型为 PoolNetCFM。优化器采用 AdamW, 权重衰减设置为 5×10^{-4} 。骨干网络学习率设置为 5×10^{-5} , 其余参数学习率设置为 3×10^{-4} 。模型共训练 25 个 epoch, 批大小为 16, 并使用余弦退火学习率调度, 最低学习率为 1×10^{-6} 。代码自动选择计算设备, 若 CUDA 可用则使用 GPU 训练。

数据集与预处理。 本文在 ECSSD 数据集上进行训练和验证。该数据集包含 1,000 张自然图像及对应的像素级显著性标注。按照固定随机种子 42, 本文将其以 7:3 的比例划分为训练集和验证集, 即 700 张图像用于训练, 300 张图像用于验证。训练阶段, 将图像及标注同步缩放至 256×256 , 随机裁剪为 224×224 , 并以 0.5 的概率进行水平翻转。验证和测试阶段不采用随机增强, 直接将图像和标注缩放至 224×224 。输入图像使用 ImageNet 均值 (0.485, 0.456, 0.406) 和标准差 (0.229, 0.224, 0.225) 归一化, 显著性标注以 0.5 为阈值二值化。

损失函数。 对于单输出模型, 训练目标由二值交叉熵损失、结构相似性损失和 Soft IoU 损失组成:

$$\mathcal{L}_{main} = \mathcal{L}_{BCE} + \mathcal{L}_{SSIM} + (1 - \text{IoU}).$$

对于带辅助输出的模型, 第一个输出作为主预测, 其余输出作为辅助预测。辅助分支采用 BCE 与 Soft IoU 的组合损失, 最终损失为:

$$\mathcal{L} = \mathcal{L}_{main} + 0.4 \cdot \mathcal{L}_{aux}.$$

评价标准。 本文采用 `py_sod_metrics` 计算显著性目标检测指标, 包括 F-measure、Weighted F-measure、MAE、E-measure 和 S-measure。每个 epoch 结束后在验证集上评估一次, 并以验证集 MAE 作为模型选择标准, 保存 MAE 最低的模型权重。测试阶段加载 `best_model.pth`, 批大小设置为 8。所有预测图均由 logits 经 Sigmoid 得到, 不使用 CRF 等后处理操作; 可视化时使用 0.5 作为二值化阈值。

4、 实验结果对比

表 6.1: 在 DUTS-TE 数据集上的定量结果对比

方法	$F_{\beta} \uparrow$	MAE↓	$S_m \uparrow$	$E_m \uparrow$
ResNet18-FCN	0.000	0.000	0.000	0.000
ResNet18-UNet	0.000	0.000	0.000	0.000
ResSOD-Improved (ours)	0.000	0.000	0.000	0.000

5、 消融实验

为验证改进方法中各模块的有效性，以 ResNet18-UNet 为基础逐步添加各模块进行消融实验，结果如表 6.2 所示。

表 6.2: 消融实验结果 (DUTS-TE)

基础	边缘分支	通道注意力	多尺度融合	混合损失	$F_{\beta} \uparrow$	MAE↓
✓					0.000	0.000
✓	✓				0.000	0.000
✓	✓	✓			0.000	0.000
✓	✓	✓	✓		0.000	0.000
✓	✓	✓	✓	✓	0.000	0.000

(注：表中数值为占位符，待实验完成后填入实际结果。)

实验分析如下：

- **边缘分支**的引入主要改善了目标边界处的预测精度，体现在 MAE 指标的下降；
- **通道注意力**有效抑制了背景噪声，提升了 F_{β} 与 S_m ；
- **多尺度融合**增强了对不同尺寸目标的检测能力，在包含小目标的样本上改善显著；
- **混合损失** (SSIM 项) 进一步提升了输出显著图的结构一致性。

6、 可视化结果分析




图 6.2: 三种方法在典型样本上的显著图可视化对比。从左至右依次为：输入图像、真值掩码、ResNet18-FCN、ResNet18-UNet、ResSOD-Improved。

七、 成员分工

表 7.1: 成员分工说明

成员	主要负责内容	具体工作
陈天祺	模型设计与训练	ResNet18-FCN 基线实现；ResSOD-Improved 网络结构设计；训练流程搭建；超参数调整
邵莫涵	数据处理与评估	数据集整理与预处理脚本；评价指标实现；消融实验设计与执行；实验结果汇总
杨欣瑞	文献调研与报告撰写	相关工作文献调研；损失函数设计；ResNet18-UNet 基线实现；报告撰写与整理

八、 总结与展望

参考文献

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 770–778, 2016.
- [2] Qiong Yan, Li Xu, Jianping Shi, and Jiaya Jia. Hierarchical saliency detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 1155–1162, 2013.